

PR-Warn++完整研究方案

研究定位

第一部分IMFGCN已经通过物理先验—残差分解、动态多图融合和图循环预测完成极端天气下的确定性风电功率预测。第二部分的目标不是重新建立一个独立预测模型，而是回答四个进一步的问题：

1. 确定性预测周围的概率分布是什么；
2. 不确定性主要来自天气、功率转换、模型认知还是数据退化；
3. 这些不确定性是否会演化成功率偏差、爬坡或预测失稳事件；
4. 如何输出风险概率、风险等级、风险来源及运行建议。

基于现有数据条件，研究应严格定位为：

极端天气下预测不确定性驱动的风电侧并网风险代理预警。

现有数据可以支持功率偏差、爬坡、预测失稳和输入退化等代理风险，但缺少电网拓扑、线路容量、母线负荷、备用容量、调度计划和电压频率数据，因此不能声称实现线路越限、真实备用不足、电压稳定或频率稳定预警。

一、文献综述与研究缺口

1.1 已核验的核心文献

1. GenCast：联合概率轨迹生成

Price et al., “Probabilistic weather forecasting with machine learning”

- 状态：正式发表；
- 期刊：Nature；
- 在线发表时间：2024年12月4日；
- 卷页：Nature 637, 84–90, 2025；
- DOI：10.1038/s41586-024-08252-9；
- 方法：条件扩散模型、图Transformer、自回归集合预测；
- 输出：多条完整的15天天气轨迹，而不是独立分位数；
- 评价：CRPS、集合校准、极端天气Brier Skill Score、经济价值、联合空间分布评价；
- 与本研究的关系：证明扩散模型适合生成具有联合时空依赖的概率轨迹，并强调联合分布对分布式风电功率等下游任务的重要性。

GenCast最值得迁移的不是模型规模，而是三点：

- 场景成员应是完整、连续、物理合理的轨迹；
- 必须同时评价边际分布和联合分布；
- 极端事件预测应评价概率价值，而不只是平均误差。

GenCast直接在全球天气状态上进行扩散生成，而PR-Warn++应仅在IMFGCN的预测误差或残差低维表示上进行扩散，降低数据量和计算需求。

2. Aurora：共享表征与任务适配

Bodnar et al., “A foundation model for the Earth system”

- 状态：正式发表；
- 期刊：Nature；
- 发表时间：2025年5月21日；
- 卷页：Nature 641, 1180–1187；
- DOI：10.1038/s41586-025-09005-y；
- 方法：异构地球系统数据预训练、统一编码器—处理器—解码器结构、下游任务微调；
- 数据：超过100万小时的异构地球系统数据；
- 与本研究的关系：支持“共享时空气象表征+多个轻量任务头”的设计，而不意味着需要训练十亿参数基础模型。

PR-Warn++可借鉴为：

$$H_t = f_{\text{shared}}(X_t, W_t, G_t, M_t)$$

并在共享表征上设置：

- 确定性残差预测头；
- 概率场景生成头；
- 风险事件识别头；
- 输入质量评估头。

不建议直接调用或重新训练大型天气基础模型，因为风场数据规模和任务尺度不足。可借鉴的是**预训练—适配思想**，而不是模型参数规模。

3. Aardvark Weather：端到端任务定制

Vaughan et al., “Aardvark weather: end-to-end data-driven weather forecasting”

- 已核验版本：arXiv公开版本；
- 标识：arXiv:2404.00411；
- 本次检索未从正式期刊原文页独立核验其期刊DOI，因此在本方案中按公开论文版本使用；
- 方法：从观测数据直接生成全球和站点预测，并针对目标变量进行端到端优化；
- 与本研究的关系：支持以最终风险任务反向约束概率预测，而不是把“预测”和“预警”完全割裂。

可迁移思想是：

$$\mathcal{L}_{\text{forecast}} + \lambda_{\text{risk}} \mathcal{L}_{\text{risk}}$$

但风险损失只能作为概率模型的辅助目标，不能牺牲分布校准性。

4. Seamless probabilistic wind power forecasting：不确定性来源分离

Dantas and Browell, “Seamless short- to mid-term probabilistic wind power forecasting”

- 状态：预印本；

- 标识: `arXiv:2502.11960` ;
- 数据: 英国73个风场、5年数据;
- 预测范围: 6—162小时;
- 核心思想: 同时传播天气预报不确定性和天气—功率转换不确定性;
- 主要发现: 较短预测期更多受转换不确定性影响, 较长预测期更多受天气预报不确定性影响, 但转换点随风场而变化。

这是PR-Warn++最重要的理论参考之一, 但必须注意预测尺度差异:

该文的最短预测期约为6小时, 而IMFGCN为10—60分钟。因此不能直接假定天气预报不确定性是主要来源。

对于10—60分钟预测, 预计局地功率转换、尾流传播、测量误差和模型认知不确定性可能更加重要。这一判断必须通过实验验证, 不能预先作为结论。

5. 缺失数据联合生成与边缘化

Wen et al., “Tackling Missing Values in Probabilistic Wind Power Forecasting: A Generative Approach”

- 状态: 预印本;
- 标识: `arXiv:2403.03631` ;
- 方法: VAE、Normalizing Flow后验、Student-t解码器、重要性重采样;
- 数据: 美国WIND Toolkit, 7年小时级数据;
- 核心贡献: 不采用“先插补、后预测”, 而是联合学习输入与预测目标的分布, 在推理阶段对缺失变量进行边缘化;
- 主要指标: CRPS。

其核心公式可迁移为:

$$p(Y^{\text{future}} | X^{\text{obs}}, M) = \int p(Y^{\text{future}}, X^{\text{mis}} | X^{\text{obs}}, M) dX^{\text{mis}}$$

但该文主要假设缺失机制为MAR。极端天气下可能存在MNAR, 例如传感器在高风速、结冰或通信过载状态下更容易失效, 因此PR-Warn++需要额外进行MNAR敏感性实验。

6. Context-Aware Conformal Prediction

Moradi et al., “Enhanced Renewable Energy Forecasting using Context-Aware Conformal Prediction”

- 状态: 预印本, 2026年6月更新至v2;
- 标识: `arXiv:2510.15780` ;
- 数据: NREL大型日前太阳能预测数据, 覆盖多个美国系统;
- 方法: 根据当前预测条件与历史样本的相似度, 对校准样本加权;
- 作用: 在不重新训练基础模型的情况下改善可靠性—区间宽度权衡。

PR-Warn++应将上下文定义为:

$$C_t = [S_t, v_t, d_t, h, r_t^{\text{miss}}, u_t^{\text{epi}}]$$

分别表示极端天气状态、风速区间、风向扇区、预测步长、缺失率和认知不确定性。

7. 天气集合、扩散和保形方法的直接比较

Bruninx et al., “Probabilistic Wind Power Forecasting with Tree-Based Machine Learning and Weather Ensembles”

- 状态：预印本；
- 标识：arXiv:2602.13010；
- 数据：比利时海上风场4年数据；
- 比较方法：Conformalized Quantile Regression、NGBoost和条件扩散模型；
- 主要结果：在该研究设置中，条件扩散模型取得最佳综合概率预测表现，天气集合也能改善点预测。

该结果支持扩散模型作为候选方法，但不能据此认定扩散模型在任何风场都必然优于Normalizing Flow或分位数回归。

8. Aleatoric—Epistemic方差分解

Chen, Yu and Muttaqi, “A Posterior-Predictive Variance Decomposition for Epistemic and Aleatoric Uncertainty in Wind Power Forecasting”

- 状态：2026年预印本；
- 标识：arXiv:2605.22390；
- 方法：异方差神经网络、贝叶斯后验近似、全方差公式；
- 验证：合成异方差、分布偏移、真实SCADA和训练数据规模变化；
- 与本研究的关系：为预测失稳风险提供“过程随机性”和“模型未知性”的区分依据。

1.2 研究缺口

结合上述文献，可以形成五个明确缺口。

缺口一：边际概率预测多，联合时空场景不足

仅输出P10、P50和P90不能准确计算：

$$P(Y_{t+h} - Y_{t+h-1} > \gamma)$$

因为爬坡风险依赖相邻时刻和不同风机之间的联合分布。

缺口二：多数模型混合了多种不确定性来源

单一预测区间无法区分：

- 天气预报本身不确定；
- 给定天气条件下的功率转换随机性；

- 模型在分布外极端天气中的认知不足；
- 输入数据缺失和异常导致的信息损失。

缺口三：缺失数据通常仍被当作预处理问题

输入缺失不仅影响点预测，还应传播到预测区间和风险概率中。

缺口四：概率预测与风险预警通常串联而非协同

大部分研究优化CRPS或Pinball Loss，却不直接评价：

- 大偏差事件；
- 上下爬坡事件；
- 漏报代价；
- 提前预警时间；
- 风险排序质量。

缺口五：全局校准不能保证极端场景下可靠

全测试集90%的覆盖率可能掩盖强风、降水、连续缺失或复合极端天气下的严重欠覆盖。

二、PR-Warn++总体技术路线

推荐的正式名称为：

PR-Warn++: Extreme-Weather-Aware Prior-Residual Joint Probabilistic Forecasting and Explainable Wind-Side Grid-Connection Risk Warning

总体框架分为六层。

第一层：确定性中心预测

$$\widehat{\mathbf{Y}}_{t+1:t+H} = \mathbf{P}_{t+1:t+H}^{phy} + \widehat{\mathbf{R}}_{t+1:t+H}$$

由IMFGCN给出未来功率的条件中心。

第二层：不确定性条件构造

构造四类随机因素：

$$\Omega = \{\Omega_w, \Omega_c, \Omega_e, \Omega_d\}$$

其中：

- Ω_w ：天气预报不确定性；
- Ω_c ：天气—功率转换随机性；
- Ω_e ：模型认知不确定性；
- Ω_d ：数据缺失与异常不确定性。

第三层：联合残差场景生成

以IMFGCN中心预测和动态图特征为条件，生成：

$$\tilde{\mathbf{E}}^{(m)} \in \mathbb{R}^{N \times H}$$

并重构：

$$\widetilde{\mathbf{Y}}^{(m)} = \mathbf{P}^{phy} + \widehat{\mathbf{R}} + \tilde{\mathbf{E}}^{(m)}$$

第四层：上下文感知保形校准

根据天气状态、预测步长、风速区间和缺失状态校准场景或预测区间。

第五层：风险映射

从概率场景计算：

- 正向和负向偏差风险；
- 向上和向下爬坡风险；
- 模型失稳风险；
- 输入退化风险；
- 尾部损失及CVaR。

第六层：解释与决策输出

输出：

{等级, 类型, 概率, 严重度, CVaR, 提前量, 来源, 建议}

三、完整数学问题定义

3.1 数据符号

设：

- N : 风机数量；
- H : 预测步数；
- L : 历史输入窗口；
- $\mathbf{Y}_t \in \mathbb{R}^N$: 风机功率；
- $\mathbf{X}_t$: SCADA运行变量；
- $\mathbf{W}_t$: 天气实测及NWP变量；
- $\mathbf{M}_t \in \{0, 1\}^{N \times L \times D}$: 缺失掩码；
- $\mathbf{S}_t$: 极端天气状态；
- $\mathcal{G}_t = \{G^{geo}, G^{corr}, G^{wind}\}$: 多图结构；
- α_t : 动态图门控权重。

模型目标是学习：

$$p(\mathbf{Y}_{t+1:t+H} \mid \mathbf{X}_{t-L+1:t}^{obs}, \mathbf{W}_{t-L+1:t+H}^{obs}, \mathbf{M}_t, \mathbf{S}_t, \mathcal{G}_t)$$

3.2 物理残差与预测误差的区别

物理残差定义为：

$$\mathbf{R}_{t+h} = \mathbf{Y}_{t+h} - \mathbf{P}_{t+h}^{phy}$$

IMFGCN预测物理残差：

$$\widehat{\mathbf{R}}_{t+h} = f_{\theta}(\mathbf{X}, \mathbf{W}, \mathcal{G}, \mathbf{M})$$

确定性功率预测为：

$$\widehat{\mathbf{Y}}_{t+h} = \mathbf{P}_{t+h}^{phy} + \widehat{\mathbf{R}}_{t+h}$$

最终预测误差为：

$$\mathbf{E}_{t+h} = \mathbf{Y}_{t+h} - \widehat{\mathbf{Y}}_{t+h} = \mathbf{R}_{t+h} - \widehat{\mathbf{R}}_{t+h}$$

第二部分应建模的是 $\mathbf{E}$ 的联合概率分布，而不是再次预测完整的物理残差 $\mathbf{R}$ 。

3.3 分层预测分布

不建议简单写成：

$$E = E_w + E_c + E_e + E_d$$

因为不同来源之间存在非线性交互，且这种加性分解通常不可识别。

更严谨的表达为：

$$p(\mathbf{Y}^{future} \mid \mathcal{I}_t) = \int p_{\phi}(\mathbf{Y}^{future} \mid \mathbf{W}^{future}, \mathbf{X}^{complete}, \theta, \mathcal{G}_t) q_w(\mathbf{W}^{future} \mid \mathcal{I}_t) \cdot q_e(\theta \mid \mathcal{D}) q_d(\mathbf{X}^{mis} \mid \mathbf{X}^{obs}, \mathbf{M}) d\mathbf{W} d\theta d\mathbf{X}$$

其中：

- q_w 传播天气不确定性；
- p_{ϕ} 描述给定天气下的转换随机性；
- $q_e(\theta \mid \mathcal{D})$ 描述模型认知不确定性；
- q_d 传播缺失输入不确定性。

各来源贡献应通过嵌套Monte Carlo、全方差公式或Shapley方差分解估计，而非强行对每个误差样本进行唯一加性拆分。

3.4 Aleatoric与Epistemic分解

在固定天气和输入条件下：

$$\text{Var}(\mathbf{Y} \mid \mathcal{I}) = \underbrace{\mathbb{E}_{\theta}[\text{Var}(\mathbf{Y} \mid \mathcal{I}, \theta)]}_{U^{\text{aleatoric}}} + \underbrace{\text{Var}_{\theta}[\mathbb{E}(\mathbf{Y} \mid \mathcal{I}, \theta)]}_{U^{\text{epistemic}}}$$

其中Aleatoric仍可进一步按条件实验拆分为天气和功率转换贡献，但需要真实天气集合或历史NWP误差数据支撑。

四、网络结构、模块设计与生成方法选择

4.1 生成方法比较

方法	联合分布	重尾/多峰	训练稳定性	采样速度	适合当前任务程度
Quantile Regression	弱	中	高	高	适合作为强基线
Copula	中	中	高	高	适合低维联合校准
Deep Ensemble+分布头	中	中	高	高	适合不确定性分解
Conditional VAE	中	中	较高	高	适合缺失数据边缘化
Normalizing Flow	强	强	中	高	数据量中等时很有竞争力
GAN	强	强	较低	高	易模式坍缩，不推荐主模型
Conditional Diffusion	强	强	中	较低	最适合联合重尾场景生成
Stochastic Interpolant	强	强	中	中	前沿但工程成熟度较低

4.2 推荐方案

主模型选择：

动态图条件的低维潜空间残差扩散模型。

而不是直接对 $N \times H$ 功率矩阵进行大型扩散。

理由：

1. IMFGCN已经提供高质量条件中心；
2. 预测误差比原始功率具有更小动态范围；
3. 潜空间压缩可降低样本和计算需求；
4. 扩散模型适合多峰、异方差和重尾分布；
5. 动态图条件可保持风机间依赖；

6. DDIM或蒸馏采样可将推理步数减少到10—20步。

适用条件：

- 至少具有跨季节、跨极端事件的充足训练窗口；
- 训练样本数量最好达到数万级窗口；
- 极端天气样本不能只包含少数孤立事件。

若数据规模较小，推荐将**Conditional Normalizing Flow+Deep Ensemble**作为替代主模型，而把扩散模型作为扩展实验。

4.3 模块一：共享掩码感知编码器

输入

$$\mathbf{X}^{obs}, \mathbf{W}, \mathbf{M}, \mathbf{S}, \mathcal{G}$$

输出

$$\mathbf{H}_t \in \mathbb{R}^{N \times d}$$

网络结构

- 时间编码：GRU、TCN或轻量Transformer；
- 空间编码：IMFGCN动态图卷积；
- 缺失编码：数值、掩码和距离上次观测时间三元输入；
- 天气状态嵌入：强风、降水、爬坡等状态向量。

连接关系

$\mathbf{H}_t$ 共享给确定性头、扩散头、风险头和数据质量头。

失败条件

若极端状态标签过度依赖人工阈值，模型可能学习到阈值偏差。应同时输入连续气象指标，而不是只输入离散标签。

4.4 模块二：IMFGCN确定性主干

输出

$$\hat{\mathbf{R}}, \hat{\mathbf{Y}}$$

训练

先独立训练并复用第一部分结果，再在概率阶段采用较小学习率联合微调。

优势

稳定概率模型的中心位置，降低生成模型学习难度。

失败条件

若确定性中心存在明显系统偏差，扩散模型会被迫同时修正均值和分布。应在训练概率模型前完成按预测步长和天气状态的偏差诊断。

4.5 模块三：天气不确定性生成

情况A：存在真实NWP集合

直接使用：

$$\mathbf{W}_{t+1:t+H}^{(k)}, \quad k = 1, \dots, K_w$$

情况B：只有单一NWP

利用历史“NWP预测—实测天气”误差训练条件天气误差生成器：

$$\Delta \mathbf{W}^{(k)} \sim q_w(\Delta \mathbf{W} \mid \mathbf{W}^{NWP}, \mathbf{S}_t, h)$$

并生成：

$$\widetilde{\mathbf{W}}^{(k)} = \mathbf{W}^{NWP} + \Delta \mathbf{W}^{(k)}$$

重要限制

若没有历史NWP发布时刻对应的预测档案，不能严格识别天气预报不确定性。此时只能研究“气象输入扰动敏感性”，不得称为真实NWP不确定性传播。

4.6 模块四：缺失变量边缘化

训练一个掩码条件生成器：

$$q_d(\mathbf{X}^{mis} \mid \mathbf{X}^{obs}, \mathbf{M}, \mathbf{H}_t)$$

推理阶段生成多个可能的完整输入：

$$\widetilde{\mathbf{X}}^{(1)}, \dots, \widetilde{\mathbf{X}}^{(K_d)}$$

最终预测分布为：

$$p(\mathbf{Y} \mid \mathbf{X}^{obs}) \approx \frac{1}{K_d} \sum_{k=1}^{K_d} p(\mathbf{Y} \mid \widetilde{\mathbf{X}}^{(k)})$$

推荐结构

- 轻量VAE+Normalizing Flow后验；
- Student-t解码器；
- 输入掩码显式编码；

- 对连续块缺失加入时间平滑约束。

替代方案

若训练样本不足，可采用多重插补+模型集成，但必须传播多个插补结果，而不能只用单点插补。

4.7 模块五：Epistemic不确定性

推荐使用 $K_e = 5$ 个独立初始化的深度集成模型：

$$\theta_k \sim q_e(\theta|\mathcal{D})$$

认知不确定性：

$$U_{i,h}^{epi} = \text{Var}_k [\mathbb{E}(Y_{i,h} | \theta_k)]$$

为什么优先Deep Ensemble

相较于MC Dropout：

- 更容易形成模型间真实差异；
- 对分布偏移通常更敏感；
- 实现和解释更直接。

代价是训练成本增加。

4.8 模块六：图条件潜空间残差扩散

首先将误差轨迹编码到潜空间：

$$\mathbf{Z}_0 = \text{Enc}_{lat}(\mathbf{E})$$

前向加噪：

$$\mathbf{Z}_s = \sqrt{\alpha_s} \mathbf{Z}_0 + \sqrt{1 - \alpha_s} \epsilon$$

去噪网络学习：

$$\hat{\epsilon} = \epsilon_\phi(\mathbf{Z}_s, s, \mathbf{H}_t, \mathbf{S}_t, \alpha_t, \widetilde{\mathbf{W}})$$

扩散损失：

$$\mathcal{L}_{diff} = \mathbb{E} \|\epsilon - \hat{\epsilon}\|_2^2$$

解码后得到：

$$\widetilde{\mathbf{E}}^{(m)} = \text{Dec}_{lat}(\widetilde{\mathbf{Z}}^{(m)})$$

时空条件

去噪器采用：

- 时间维一维卷积或Temporal Transformer；
 - 风机维动态图注意力；
 - 天气状态FiLM调制；
 - 预测步长嵌入；
 - 缺失率和认知不确定性嵌入。
-

4.9 物理约束

功率约束：

$$0 \leq \widetilde{Y}_{i,h}^{(m)} \leq P_i^{rated}$$

风速—功率约束：

- 低于切入风速时功率接近0；
- 额定区间功率受上限约束；
- 高于切出风速时允许停机概率增大；
- 不强制使用理想制造商功率曲线，应允许限功率和控制行为。

空间一致性约束：

$$\mathcal{L}_{graph} = \sum_h \text{Tr} \left[\widetilde{\mathbf{E}}_h^\top L_t \widetilde{\mathbf{E}}_h \right]$$

时间变化约束：

$$\mathcal{L}_\Delta = \|\Delta \widetilde{\mathbf{Y}} - \Delta \mathbf{Y}\|_1$$

不能过度使用平滑损失，否则会抑制真实爬坡事件。

4.10 上下文感知保形校准

定义标准化非一致性分数：

$$s_j = \max_{i,h} \frac{|Y_{j,i,h} - \widehat{Y}_{j,i,h}|}{\widehat{\sigma}_{j,i,h} + \epsilon}$$

上下文距离：

$$d(C_j, C_t) = \sum_r \omega_r d_r(C_{j,r}, C_{t,r})$$

权重：

$$w_j(C_t) = \frac{\exp[-d(C_j, C_t)/\tau]}{\sum_l \exp[-d(C_l, C_t)/\tau]}$$

由加权经验分位数得到 $q_{1-\alpha}(C_t)$ 。

最终区间：

$$\mathcal{C}_{i,h} = [\widehat{Y}_{i,h} - q_{1-\alpha}(C_t)\widehat{\sigma}_{i,h}, \widehat{Y}_{i,h} + q_{1-\alpha}(C_t)\widehat{\sigma}_{i,h}]$$

关键原则

保形预测应作为**训练后的校准层**，而不是联合损失的一部分。否则不能再直接声称具有标准保形覆盖性质。

在时间序列和分布偏移条件下，严格交换性通常不成立，因此论文中应表述为：

加权或自适应保形提供经验上的局部覆盖改善，而不是无条件的有限样本条件覆盖保证。

4.11 联合损失函数

建议基础训练目标为：

$$\mathcal{L}_{total} = \mathcal{L}_{point} + \lambda_1 \mathcal{L}_{diff} + \lambda_2 \mathcal{L}_{energy} + \lambda_3 \mathcal{L}_{variogram} + \lambda_4 \mathcal{L}_{extreme} + \lambda_5 \mathcal{L}_{risk} + \lambda_6 \mathcal{L}_{physics} + \lambda_7 \mathcal{L}_{unc}.$$

点预测损失

$$\mathcal{L}_{point} = \|\mathbf{Y} - \widehat{\mathbf{Y}}\|_1 + \eta \|\mathbf{Y} - \widehat{\mathbf{Y}}\|_2^2$$

Energy Score

$$ES = \frac{1}{M} \sum_m \|\widetilde{\mathbf{Y}}^{(m)} - \mathbf{Y}\| - \frac{1}{2M^2} \sum_{m,n} \|\widetilde{\mathbf{Y}}^{(m)} - \widetilde{\mathbf{Y}}^{(n)}\|$$

Variogram Score

用于约束不同风机和不同预测时刻之间的相关结构：

$$VS = \sum_{a,b} w_{ab} \left(|Y_a - Y_b|^p - \frac{1}{M} \sum_m |\widetilde{Y}_a^{(m)} - \widetilde{Y}_b^{(m)}|^p \right)^2$$

极端事件损失

$$\mathcal{L}_{extreme} = \sum_k \omega_k \text{BCE}(\widehat{p}_k, z_k)$$

极端事件正样本权重大于正常样本。

风险损失

可采用成本敏感Brier损失：

$$\mathcal{L}_{risk} = c_{FN}z(1 - \hat{p})^2 + c_{FP}(1 - z)\hat{p}^2$$

其中 $c_{FN} > c_{FP}$ 。

不确定性分解损失

采用异方差Student-t或Gaussian NLL，并结合 β -NLL缓解均值-一方差训练失衡。

权重选择

不建议人工一次性确定全部 λ 。推荐：

1. 各任务损失归一化；
2. 在验证集使用不确定性加权或GradNorm；
3. 对 λ_{risk} 、 $\lambda_{physics}$ 进行单独敏感性分析；
4. 确保风险损失不会显著破坏CRPS和覆盖率。

五、模型训练算法伪代码

Algorithm 1: PR-Warn++ Training

Input:

SCADA X , weather W , NWP forecasts W_{nwp} ,
power Y , masks M , extreme states S , graphs G

1. Split data chronologically into:
Train / Validation / Calibration / Test
Group complete extreme-weather events into only one subset.
2. Build physical prior:
 $P_{phy} = \text{PhysicalPrior}(W, \text{turbine parameters})$
3. Train deterministic IMFGCN:
 $R = Y - P_{phy}$
 $R_{hat} = \text{IMFGCN}(X, W, G, M)$
 $Y_{hat} = P_{phy} + R_{hat}$
minimize L_{point}
4. Diagnose deterministic bias by:
horizon, wind-speed region, weather state, turbine.
5. Train missing-data generator:
learn $q_d(X_{mis} | X_{obs}, M, H)$
using artificial masks + naturally missing samples.
6. Train K_e independent probabilistic models:
for each ensemble member k :
initialize independent parameters

```
load deterministic backbone
train latent residual diffusion model
condition on H, S, graph gates and weather samples
minimize:
    L_point + L_diff + L_energy
    + L_variogram + L_physics
```

7. Construct historical scenario forecasts on validation set.

8. Construct risk labels from realized power:

positive/negative deviation,
upward/downward ramp,
tail loss.

9. Train cost-sensitive risk head:

inputs = scenario statistics + uncertainty features
output = event probabilities and severity
minimize $L_{\text{risk}} + L_{\text{extreme}}$

10. Freeze all forecasting parameters.

11. Fit context-aware conformal calibrator
on the independent calibration set.

12. Select risk thresholds by minimizing
validation expected cost under asymmetric loss.

Output:

deterministic backbone,
missing-data generator,
ensemble diffusion models,
conformal calibrator,
risk head and thresholds.

六、推理与在线校准算法

6.1 推理采样

对于每次预测：

1. 生成 K_w 个天气样本；
2. 生成 K_d 个缺失输入样本；
3. 使用 K_e 个模型集成成员；
4. 每个条件组合生成若干扩散场景；
5. 汇总形成 M 条最终功率轨迹。

为避免组合爆炸，不采用完整笛卡尔积，可使用分层抽样或拉丁超立方抽样。

Algorithm 2: Online Inference

Input:

current observations X_{obs} ,
weather/NWP W ,
mask M ,
graphs G ,
weather state S

1. Compute P_{phy} , H and deterministic center Y_{hat} .
2. Sample weather trajectories:
 $W^{\wedge}(1), \dots, W^{\wedge}(K_w)$
3. Sample missing-variable proposals:
 $X_{\text{complete}}^{\wedge}(1), \dots, X_{\text{complete}}^{\wedge}(K_d)$
4. For $m = 1, \dots, M$:
 select weather sample
 select missing-data sample
 select ensemble member
 sample latent residual trajectory by DDIM
 decode $E^{\wedge}(m)$
 $Y^{\wedge}(m) = \text{clip}(P_{\text{phy}} + R_{\text{hat}} + E^{\wedge}(m))$
5. Apply context-aware conformal scaling.
6. Calculate:
 quantiles, CRPS-related statistics,
 uncertainty components,
 event probabilities,
 VaR/CVaR and lead times.
7. Apply risk fusion, persistence rules and override logic.
8. Generate structured warning and explanation.

6.2 在线校准

采用滚动校准窗口：

$$\mathcal{D}_{\text{cal},t} = \{t - W_c, \dots, t - 1\}$$

并对近期样本给予更高权重：

$$w_j^{\text{time}} = \rho^{t-j}$$

若近期覆盖率持续低于目标，则扩大校准系数；若持续过度覆盖，则缓慢收紧。

应避免在每个时刻剧烈调整区间，否则会导致预警等级抖动。

七、风险计算公式

7.1 正向功率偏差风险

实际功率高于点预测：

$$A_{dev}^+(h) = \{Y_{t+h} - \widehat{Y}_{t+h} > \tau_h^+\}$$

概率：

$$p_{dev}^+(h) = \frac{1}{M} \sum_m \mathbb{I} [Y_{t+h}^{(m)} - \widehat{Y}_{t+h} > \tau_h^+]$$

严重度损失：

$$L_{dev}^+ = \max(Y - \widehat{Y} - \tau^+, 0)$$

7.2 负向功率偏差风险

$$A_{dev}^-(h) = \{\widehat{Y}_{t+h} - Y_{t+h} > \tau_h^-\}$$

$$L_{dev}^- = \max(\widehat{Y} - Y - \tau^-, 0)$$

正向和负向风险必须分别报告，因为其运行含义不完全相同。

7.3 向上爬坡风险

$$\Delta Y_h = Y_{t+h} - Y_{t+h-1}$$

$$A_{ramp}^+(h) = \{\Delta Y_h > \gamma_h^+\}$$

$$p_{ramp}^+(h) = \frac{1}{M} \sum_m \mathbb{I} [\Delta Y_h^{(m)} > \gamma_h^+]$$

7.4 向下爬坡风险

$$A_{ramp}^-(h) = \{-\Delta Y_h > \gamma_h^-\}$$

除单步变化外，还应定义窗口爬坡：

$$\Delta_k Y_h = Y_{t+h} - Y_{t+h-k}$$

防止一个持续爬坡事件被拆成多个较小单步变化。

7.5 VaR与CVaR

对于任意风险损失 L :

$$VaR_\alpha(L) = \inf\{l : P(L \leq l) \geq \alpha\}$$

$$CVaR_\alpha(L) = \mathbb{E}[L \mid L \geq VaR_\alpha(L)]$$

场景估计:

$$\widehat{CVaR}_\alpha = \frac{\sum_m L^{(m)} \mathbb{I}[L^{(m)} \geq \widehat{VaR}_\alpha]}{\sum_m \mathbb{I}[L^{(m)} \geq \widehat{VaR}_\alpha]}$$

7.6 模型预测失稳风险

定义:

$$R_{unstable} = \sigma(a_1 \widetilde{U}^{epi} + a_2 D_{OOD} + a_3 E_{cal} + a_4 D_{ensemble})$$

其中:

- $\widetilde{U}^{epi}$: 归一化认知不确定性;
- D_{OOD} : 输入与训练分布距离;
- E_{cal} : 近期覆盖率偏差;
- $D_{ensemble}$: 不同模型之间的预测分歧。

它是**模型可靠性风险**, 不是电网失稳概率。

7.7 输入数据退化风险

定义数据质量特征:

$$\mathbf{q}_d = [r_{miss}, l_{block}, r_{abnormal}, r_{delay}, r_{impute}]$$

比较实际缺失条件和完整输入反事实条件下的预测扩张:

$$\Delta U^{data} = U(\mathbf{X}^{obs}, \mathbf{M}) - U(\mathbf{X}^{cf}, \mathbf{0})$$

风险:

$$R_{data} = g(\mathbf{q}_d, \Delta U^{data})$$

7.8 极端天气尾部偏差风险

定义归一化损失:

$$L_{tail} = \max \left(\frac{|Y - \widehat{Y}|}{Prated} - \tau_{tail}, 0 \right)$$

输出：

- $P(L_{tail} > 0)$;
- $VaR_{0.95}$;
- $CVaR_{0.95}$;
- 极端状态条件下的风险比：

$$RR = \frac{P(L_{tail} > 0 \mid S = \text{extreme})}{P(L_{tail} > 0 \mid S = \text{normal})}$$

7.9 提前预警时间

若事件在实际时刻 $t + h_e$ 发生，而模型第一次持续触发预警的时刻为 $t - h_w$ ，则：

$$LeadTime = h_e + h_w$$

实际评价中，应要求连续 K 次预测超过风险阈值才视为成功触发，避免偶然单点报警。

7.10 标签性质

可由真实功率直接构造的标签

- 正向偏差；
- 负向偏差；
- 向上爬坡；
- 向下爬坡；
- 尾部偏差。

代理或弱监督标签

- 模型失稳；
- 输入退化；
- 分布偏移。

不能从现有数据构造的真实标签

- 线路越限；
- 电压失稳；
- 频率失稳；
- 真实备用不足；
- 电网故障概率。

八、风险融合、分级与归因

8.1 风险向量

$$\mathbf{r}_{t,h} = [p_{dev}^+, p_{dev}^-, p_{ramp}^+, p_{ramp}^-, R_{unstable}, R_{data}, CVaR_{tail}]$$

8.2 推荐融合方式

不建议使用固定人工加权和作为主要方法。

推荐采用：

成本敏感的单调有序逻辑回归或单调广义加性模型。

优点：

- 风险概率或CVaR升高时，风险等级不会反向下降；
- 参数容易解释；
- 所需样本量低于复杂多任务网络；
- 审稿人容易接受。

风险等级：

$$P(\text{Level} \leq l \mid \mathbf{r}) = \sigma(b_l - \mathbf{w}^\top \mathbf{r})$$

其中约束：

$$w_j \geq 0$$

8.3 贝叶斯决策分级

更理想的方式是将风险等级解释为行动等级：

$$a^* = \arg \min_{a \in \mathcal{A}} \frac{1}{M} \sum_m C(a, \mathbf{Y}^{(m)})$$

例如：

- Level 1：正常监测；
- Level 2：提高滚动预测频率；
- Level 3：人工复核并关注调节裕度；
- Level 4：采用保守预测边界和应急运行流程。

由于没有真实调度和备用数据，成本函数应使用相对代理成本，不应直接声称是实际电网运行成本。

8.4 单项高风险兜底

即使综合等级较低，只要满足：

$$p_{ramp}^- > T_{critical}$$

或：

$$R_{unstable} > T_{model}$$

则直接提升至高级别预警。

8.5 持续性与防抖

采用以下任一规则：

- 最近3次预测中至少2次超过阈值；
- 风险概率指数移动平均；
- 隐马尔可夫模型平滑；
- 高等级快速上升、低等级缓慢解除的迟滞机制。

例如：

$$\bar{R}_t = \beta R_t + (1 - \beta) \bar{R}_{t-1}$$

8.6 三级风险解释

第一级：不确定性来源贡献

采用嵌套Monte Carlo或Shapley方差分解，计算：

$$[C_w, C_c, C_e, C_d]$$

且：

$$C_w + C_c + C_e + C_d + C_{interaction} = 1$$

应保留交互项，不能强制四项贡献严格加和为1而忽略交互。

第二级：输入变量解释

推荐：

- 对风险头使用SHAP；
- 对共享编码器使用Integrated Gradients；
- 对天气变量和SCADA变量进行分组解释；
- 动态图门控权重作为结构状态描述。

门控权重和注意力权重不能直接解释为因果贡献，因为：

1. 权重存在非唯一性；
2. 权重受归一化约束；
3. 两个高度相关变量可能互相替代；
4. 高权重不等于移除该变量会导致大风险变化。

第三级：反事实归因

构建物理可行反事实：

- 将降水恢复为正常水平；
- 修复缺失SCADA；
- 将风向变化限制在历史正常范围；
- 使用正常天气图门控；
- 将认知不确定性替换为训练分布内水平。

贡献：

$$\Delta R_k = R(\mathbf{X}) - R(\mathbf{X}^{cf,k})$$

反事实必须符合物理范围，不能任意改变单个变量而破坏变量之间的一致性。

九、实验方案与消融实验

9.1 数据划分

推荐：

- 训练集：最早60%—65%；
- 验证集：随后10%—15%；
- 校准集：随后10%；
- 测试集：最后15%—20%。

要求：

1. 严格时间顺序；
 2. 一次完整极端天气事件只能位于一个数据子集；
 3. 同一降水或强风过程的相邻窗口不能跨训练和测试集；
 4. 校准集不能参与模型训练和超参数选择；
 5. 额外设置跨季节或跨年度测试。
-

9.2 场景划分

至少包括：

1. 正常天气；
2. 低风速；

3. 中风速；
 4. 高风速；
 5. 极高风速及接近切出状态；
 6. 强降水；
 7. 向上爬坡；
 8. 向下爬坡；
 9. 强风+降水；
 10. 风向快速转变；
 11. 随机缺失；
 12. 连续块缺失；
 13. 单风机传感器异常；
 14. 多风机通信中断；
 15. 时间分布偏移；
 16. 风机或风场空间迁移。
-

9.3 基线模型

确定性基线

- Persistence；
- XGBoost；
- LSTM/GRU；
- AGCRN；
- 原始IMFGCN。

概率边际基线

- Gaussian/Student-t异方差回归；
- Quantile Regression；
- NGBoost；
- Conformalized Quantile Regression；
- Deep Ensemble。

联合场景基线

- Gaussian Copula；
- Conditional VAE；
- Conditional Normalizing Flow；
- GAN；
- 非潜空间扩散；
- 推荐的图条件潜空间扩散。

缺失数据基线

- 均值/线性插补；
 - KNN；
 - BRITS或时序插补模型；
 - 多重插补；
 - 联合边缘化模型。
-

9.4 评价指标

确定性

- RMSE;
- MAE;
- R^2 ;
- 按预测步长和天气状态分别报告。

边际概率预测

- CRPS;
- Pinball Loss;
- PICP;
- PINAW或MPIW;
- Winkler Score;
- PIT或Rank Histogram;
- Spread—Skill Ratio。

联合分布

- Energy Score;
- Variogram Score;
- 风机间相关矩阵误差;
- 时间增量相关误差;
- 场景多样性;
- 极端爬坡持续时间分布误差。

极端事件

- Brier Score;
- Brier Skill Score;
- AUPRC;
- AUROC;
- Event-F1;
- 漏报率;
- 误报率;
- 平均提前预警时间;
- 极端加权CRPS。

校准

- 全局覆盖率;
- 按天气状态覆盖率;
- 按预测步长覆盖率;
- 按风速区间覆盖率;
- 按缺失率覆盖率;
- 最大条件覆盖偏差。

风险

- 风险概率Brier Score;

- Expected Calibration Error;
- Expected Cost;
- CVaR误差;
- 风险等级Macro-F1;
- 有序等级Quadratic Weighted Kappa;
- NDCG或风险排序相关系数。

计算效率

- 单次预测时间;
- 每100条场景生成时间;
- GPU显存;
- 参数量;
- 在线校准耗时。

9.5 不确定性分解验证

由于没有真实不确定性标签，应设计控制实验：

Aleatoric验证

逐步注入不同强度的异方差噪声，预期：

$$U^{aleatoric} \uparrow, \quad U^{epistemic} \text{相对稳定}$$

Epistemic验证

- 减少训练数据;
- 测试新季节;
- 测试未见极端天气;
- 测试新风机。

预期：

$$U^{epistemic} \uparrow$$

数据不确定性验证

逐渐提高缺失率和连续缺失长度，检验：

$$U^{data} \uparrow$$

并评价是否准确识别受影响最大的风机和变量。

9.6 统计显著性

- 使用时间块Bootstrap构造95%置信区间;
- 极端事件按完整事件进行重采样，而不是按单个时间点重采样;
- 对CRPS、Energy Score和事件损失使用配对块Bootstrap;

- 对多模型比较进行多重检验校正。

9.7 消融实验

编号	消融模型	验证问题
A1	去掉物理先验	先验是否降低生成难度
A2	去掉先验—残差分解	直接生成功率是否更差
A3	去掉天气集合	天气不确定性贡献
A4	不区分AU与EU	分解对失稳识别是否有效
A5	去掉动态图条件	联合空间结构是否退化
A6	去掉扩散模型	生成模型的必要性
A7	独立分位数替代联合场景	爬坡风险是否失真
A8	去掉上下文保形	极端状态覆盖率变化
A9	全局保形替代局部保形	局部校准增益
A10	先插补后预测	缺失传播是否必要
A11	去掉风险感知损失	风险识别增益与校准代价
A12	去掉反事实解释	解释可信度与稳定性
A13	完整空间扩散替代潜空间扩散	计算成本与效果
A14	Flow替代Diffusion	数据量较小时谁更适合
A15	单模型替代Deep Ensemble	Epistemic识别能力

十、五条可用于论文的创新点

创新点一：物理先验中心化的联合残差概率建模

在IMFGCN先验—残差确定性预测基础上，仅对最终预测误差进行生成建模，避免概率模型重复学习主要风速—功率转换趋势。

创新点二：多源不确定性的分层传播与诊断

通过天气集合、条件转换分布、深度集成和缺失变量边缘化，分别传播天气、Aleatoric、Epistemic和数据退化不确定性，并通过方差分解与控制实验验证其响应合理性。

创新点三：动态图条件的时空联合潜空间扩散

生成多风机、多步、时间连续且空间相关的功率场景，并通过动态多图、风向尾流信息和功率约束保持场景物理可行性。

创新点四：极端状态与数据质量感知的保形校准

根据极端天气、预测步长、风速区间、风向和数据缺失状态动态选择或加权校准样本，提高分布偏移场景下的经验条件覆盖可靠性。

创新点五：面向尾部事件的预测—风险—解释闭环

将概率场景映射为偏差、爬坡、模型失稳、数据退化和尾部CVaR风险，并通过不确定性来源、变量归因和物理反事实生成可解释的预警结果。

十一、论文题目候选

题目一：最推荐

Prior-Residual Joint Probabilistic Wind Power Forecasting and Explainable Risk Warning under Extreme Weather

题目二：突出扩散模型

Graph-Conditioned Residual Diffusion for Extreme-Weather Wind Power Scenario Forecasting and Risk Warning

题目三：突出不确定性分解

Source-Aware Uncertainty Propagation for Probabilistic Wind Power Forecasting and Wind-Side Grid-Connection Risk Warning

题目四：突出校准与风险

Context-Calibrated Probabilistic Wind Power Forecasting for Extreme Ramp and Deviation Risk Warning

题目五：完整但较长

Physics-Guided Prior-Residual Diffusion with Context-Aware Conformal Calibration for Wind Power Forecasting and Explainable Risk Warning

十二、Introduction逻辑

第一段：应用背景

随着风电渗透率提高，单一点预测无法充分支持极端天气下的运行判断。调度人员不仅需要知道最可能功率，还需要知道预测区间、尾部事件概率和预测可靠性。

第二段：现有概率预测不足

现有方法主要采用分位数回归、参数分布或独立预测区间，难以保持多风机、多预测步长之间的联合依赖，因而不能准确评价爬坡和聚合偏差风险。

第三段：不确定性混合问题

现有概率预测通常将天气误差、功率转换随机性、模型未知性和输入缺失混合在单一分布中，导致风险来源无法区分，也无法判断风险应通过增加数据还是保守运行来缓解。

第四段：校准和决策问题

全局平均校准不能保证极端天气和数据退化条件下的可靠性。同时，多数方法以CRPS为最终目标，缺少概率预测到尾部风险、预警等级和解释输出的闭环。

第五段：本文工作

本文在IMFGCN确定性先验—残差框架上，提出PR-Warn++，通过分层不确定性传播、动态图条件联合扩散、上下文感知保形校准以及成本敏感风险映射，实现极端天气下可解释的风电侧风险代理预警。

十三、Method章节详细目录

3.1 Problem Formulation

- 数据和图结构定义；
- 物理先验；
- 物理残差和预测误差；
- 联合概率预测目标；
- 风险代理定义。

3.2 Deterministic Prior-Residual Backbone

- 物理先验构建；
- IMFGCN编码器；
- 动态多图融合；
- 确定性残差预测。

3.3 Hierarchical Uncertainty Propagation

- 天气集合或天气误差生成；
- 缺失变量边缘化；
- Aleatoric分布；
- Deep Ensemble Epistemic估计；
- 总预测分布。

3.4 Graph-Conditioned Latent Residual Diffusion

- 潜空间编码；
- 正向扩散；
- 动态图条件去噪；
- 场景解码；
- 快速DDIM采样。

3.5 Physical and Spatiotemporal Constraints

- 功率上下界；
- 功率曲线软约束；
- 动态图一致性；
- 时间增量和爬坡约束。

3.6 Context-Aware Conformal Calibration

- 非一致性分数；
- 上下文距离；
- 加权分位数；
- 在线自适应更新；
- 轨迹联合覆盖。

3.7 Risk Proxy Quantification

- 偏差风险；
- 爬坡风险；
- 尾部风险；
- 模型失稳；
- 数据退化；
- VaR/CVaR和提前量。

3.8 Cost-Sensitive Risk Grading

- 风险向量；
- 有序分类；
- 非对称成本；
- 高风险兜底；
- 时间防抖。

3.9 Multi-Level Risk Explanation

- 来源方差分解；
- SHAP和Integrated Gradients；
- 图结构解释；
- 反事实场景。

3.10 Training and Online Inference

- 分阶段训练；
- 联合微调；
- 推理采样；
- 在线校准；
- 复杂度分析。

十四、可能的审稿人质疑及应对

质疑一：模块过多，创新是否只是拼接

应对

以一条统一问题主线组织模型：

确定性中心—分层场景生成—局部校准—风险映射。

通过逐层消融证明每个模块解决独立缺口，避免将所有先进方法同时作为主创新。

质疑二：为什么必须使用扩散模型

应对

与Quantile、Copula、VAE、Flow和Deep Ensemble进行严格比较。若扩散模型未在Energy Score、Variogram Score和爬坡风险上显著领先，不应强行声称其最优。

主要论据应是联合时空分布和重尾建模能力，而不是“模型更新”。

质疑三：10—60分钟为什么需要NWP不确定性

应对

设置天气集合消融，量化各预测步长中的来源贡献。预期在10分钟尺度天气不确定性贡献较小，但在60分钟或强天气突变时可能增加。若没有真实NWP集合，只称为天气输入扰动敏感性。

质疑四：不确定性分解是否可识别

应对

不声称对每个样本得到唯一真实来源分解。采用层次生成机制、全方差公式、嵌套采样和控制实验验证来源响应的一致性，并显式保留交互贡献。

质疑五：保形预测在时间序列上是否有严格保证

应对

明确标准交换性不成立。将方法描述为加权、自适应或近似局部保形校准，重点报告经验条件覆盖和最差子群覆盖，不夸大理论保证。

质疑六：风险预警是否是真实电网风险

应对

全文统一使用：

- 风电侧风险代理；
- 预测偏差风险；
- 爬坡运行压力代理；
- 模型可靠性风险；
- 数据质量风险。

不使用“电网安全稳定风险”作为总称，并在局限性中明确缺少网络和调度数据。

质疑七：风险等级缺少真实人工标签

应对

事件概率直接由真实功率构造；风险等级依据成本敏感规则和代理成本生成。风险等级评价采用事件损失和排序价值，而不是声称具有真实调度员标注。

质疑八：极端样本太少

应对

- 事件级交叉验证；
- 极端样本加权；
- 重尾分布；
- 场景增强；
- 合成扰动只用于鲁棒性验证，不混入最终真实测试结果；
- 报告置信区间而非单个平均值。

质疑九：注意力或门控权重被错误解释

应对

将门控权重仅作为描述性证据，主要解释结果来自SHAP、IG、方差分解和物理可行反事实。

质疑十：在线计算是否可接受

应对

- 潜空间扩散；
 - DDIM 10—20步；
 - 批量并行采样；
 - 场景数量敏感性分析；
 - 将100、200、500条场景的风险估计稳定性和时间成本同时报告。
-

十五、论文框架图文字版说明

整张图从左到右分为五个区域。

区域A：多源输入

上方输入：

- 风机SCADA；
- 功率历史；
- 实测天气；
- NWP；
- 风机位置；
- 缺失掩码；
- 极端天气状态。

下方构建三类图：

- 地理图；
- 差分相关图；
- 风感知图。

区域B：IMFGCN确定性中心

物理支路：

$$W^{future} \rightarrow P^{phy}$$

数据支路：

$$X, W, G, M \rightarrow \text{Shared Encoder} \rightarrow \hat{R}$$

二者相加：

$$\hat{Y} = P^{phy} + \hat{R}$$

共享编码器同时输出动态图门控权重和隐藏状态。

区域C：分层概率生成

四个条件分支汇入残差场景生成器：

1. 天气集合或天气误差场景；
2. 缺失变量边缘化场景；
3. Deep Ensemble模型成员；
4. Aleatoric残差扩散噪声。

中心模块为：

Graph-Conditioned Latent Residual Diffusion

输出：

$$E^{(1)}, E^{(2)}, \dots, E^{(M)}$$

与确定性中心相加形成：

$$Y^{(1)}, Y^{(2)}, \dots, Y^{(M)}$$

场景经过功率边界、运行状态和图空间一致性约束。

区域D：校准与风险映射

场景首先进入：

Extreme-State and Data-Quality-Aware Conformal Calibration

随后并行计算：

- 正向偏差风险；
- 负向偏差风险；
- 向上爬坡风险；
- 向下爬坡风险；
- 模型失稳风险；
- 数据退化风险；
- VaR与CVaR；
- 提前预警时间。

区域E：解释与输出

解释模块分为三层：

1. Weather / Conversion / Epistemic / Data来源贡献；
2. SCADA、天气变量和动态图归因；
3. 无降水、无缺失、正常风向等反事实风险变化。

最终右侧输出卡片：

风险等级：高
风险类型：向下爬坡
发生时段：未来30—40分钟
概率：78%
CVaR：额定功率的19%
主要来源：天气47%、转换26%、模型19%、数据8%
建议：提高滚动预测频率，人工复核并关注调节裕度。

图的底部用虚线表示损失函数：

$$L_{point} + L_{diff} + L_{energy} + L_{variogram} + L_{extreme} + L_{risk} + L_{physics} + L_{uncertainty}$$

保形校准位于训练完成之后，用独立校准集拟合，不通过虚线反向传播。